

Análise de Incêndios Florestais nos EUA com Machine Learning

Integrantes

- Paulo Henrique Basso Bessa - RA: 26005799-2
- Ricardo camati - RA: 22014446-2
- Caua Cesar da Silva de Oliveira - RA: 23217378-2

Resumo do projeto

Este projeto utiliza dados históricos de incêndios florestais nos Estados Unidos para investigar se é possível prever a classe de tamanho final de um incêndio a partir de informações conhecidas no registro da ocorrência, como localização, ano, dia do ano, estado e causa reportada.

O problema foi tratado como uma tarefa de classificação multiclasse. A variável alvo é `FIRE_SIZE_CLASS`, que classifica os incêndios de A até G, sendo A a menor classe e G a maior. Foram comparados três modelos de Inteligência Artificial: KNN, Random Forest e MLP.

Hipótese da equipe: atributos relacionados à localização e ao contexto da ocorrência, principalmente latitude, longitude, estado, data e causa, contêm padrões suficientes para melhorar a previsão da classe de tamanho em relação a um palpite baseado apenas na classe majoritária.

Dataset

O dataset utilizado foi o **1.88 Million US Wildfires**, disponibilizado no Kaggle:

<https://www.kaggle.com/datasets/rtatman/188-million-us-wildfires/data>

A base original reúne registros de incêndios florestais nos Estados Unidos entre 1992 e 2015. No arquivo SQLite usado neste projeto, a tabela `Fires` contém **1.880.465 registros**.

Distribuição das classes no dataset completo:

Classe	Registros	Percentual
A	666.919	35,47%
B	939.376	49,95%
C	220.077	11,70%
D	28.427	1,51%
E	14.107	0,75%
F	7.786	0,41%
G	3.773	0,20%

Como a classe B representa quase metade da base, a avaliação não deve considerar apenas acurácia.

Por isso, também foi usado o F1-score ponderado.

Preparação dos dados

O notebook lê o arquivo `wildfires_dataset.sqlite` e seleciona as seguintes colunas:

- FIRE_YEAR
- DISCOVERY_DOY
- STAT_CAUSE_DESCR
- FIRE_SIZE
- FIRE_SIZE_CLASS
- LATITUDE
- LONGITUDE
- STATE

A coluna `FIRE_SIZE` é carregada apenas para referência, mas não é usada como entrada dos modelos, porque `FIRE_SIZE_CLASS` deriva do tamanho final do incêndio. Usar `FIRE_SIZE` como feature causaria vazamento direto da resposta.

Tratamentos realizados:

- remoção de registros com valores nulos nas colunas usadas;
- filtro das classes válidas de A a G;
- amostragem de 110.000 registros com `random_state=42`;
- divisão estratificada em 100.000 registros de treino e 10.000 de teste;
- padronização das variáveis numéricas com `StandardScaler`;
- codificação das variáveis categóricas com `OneHotEncoder`.

Modelos utilizados

Foram testados diferentes conjuntos de features para cada modelo.

Modelo	Parte da disciplina	Descrição
KNN	Parte 1	Classificador baseado nos vizinhos mais próximos.
Random Forest	Parte 2	Conjunto de árvores de decisão treinadas com aleatoriedade.
MLP	Parte 2	Rede neural multicamadas com <code>early_stopping</code> .

Conjuntos de features avaliados:

- localizacao
- localizacao_estado_ano_diaAno
- localizacao_estado_causa
- tempo
- causa
- estado
- localizacao_tempo
- localizacao_causa
- localizacao_estado
- causa_estado
- todos_sem_fire_size

Avaliação dos modelos

As métricas usadas foram:

- acurácia;
- F1-score ponderado;
- matriz de confusão;
- tempo de treinamento e avaliação.

Resultados da execução atual do notebook:

Modelo	Melhor conjunto de features	Acurácia	F1-score ponderado	Tempo
KNN	localizacao_causa	57,87%	0,5553	9,14s
Random Forest	todos_sem_fire_size	61,19%	0,5865	12,01s
MLP	todos_sem_fire_size	61,32%	0,5701	4,35s

Matrizes de confusão dos melhores modelos

KNN:

Random Forest:

MLP:

Comparação dos resultados

O MLP obteve a maior acurácia da execução, com **61,32%**, mas o Random Forest teve o maior F1-score ponderado, com **0,5865**. Como o dataset é bastante desbalanceado, o F1-score ponderado é importante para analisar o desempenho além da taxa geral de acertos.

O KNN ficou abaixo dos modelos da Parte 2, mas ainda superou a classe majoritária do dataset completo, que representa aproximadamente **49,95%** dos registros. Isso indica que as features escolhidas carregam informação útil para a classificação, principalmente quando combinam localização, tempo, estado e causa.

Conclusão

Os resultados mostram que é possível prever a classe de tamanho de incêndios florestais com desempenho superior a um baseline simples baseado na classe majoritária. O melhor resultado em acurácia foi obtido pelo MLP, enquanto o Random Forest apresentou o melhor F1-score ponderado.

Para este problema, a combinação `todos_sem_fire_size` foi a mais forte nos modelos Random Forest e MLP, sugerindo que a previsão melhora quando o modelo recebe informações geográficas, temporais e categóricas em conjunto. Ainda assim, o desempenho nas classes maiores tende a ser mais difícil, pois as classes D, E, F e G possuem poucos exemplos em relação às classes A e B.

Como executar

1. Crie e ative o ambiente virtual:

```
python -m venv .venv
source .venv/bin/activate
```

No Windows PowerShell:

```
py -m venv .venv
.venv/Scripts/Activate.ps1
```

1. Instale as dependências:

```
pip install -r requirements.txt
```

1. Baixe o dataset no Kaggle:

<https://www.kaggle.com/datasets/rtatman/188-million-us-wildfires/data>

1. Coloque o arquivo SQLite na raiz do projeto com o nome:

```
wildfires_dataset.sqlite
```

1. Execute o notebook:

```
jupyter notebook main.ipynb
```

Também é possível reexecutar pelo terminal:

```
jupyter nbconvert --to notebook --execute --inplace main.ipynb --  
ExecutePreprocessor.timeout=-1
```

Modelo treinado

O projeto não armazena um arquivo de modelo treinado separado. Os modelos são treinados diretamente no notebook `main.ipynb` a partir do dataset. Para reproduzir os resultados, basta baixar o arquivo SQLite, colocá-lo na raiz do projeto e executar todas as células do notebook.

Referências

Dataset no Kaggle:

<https://www.kaggle.com/datasets/rtatman/188-million-us-wildfires/data>

Citação oficial solicitada pelo criador da base:

Short, Karen C. 2017. Spatial wildfire occurrence data for the United States, 1992-2015 [FPA_FOD_20170508]. 4th Edition. Fort Collins, CO: Forest Service Research Data Archive. <https://doi.org/10.2737/RDS-2013-0009.4>

Reconhecimento de uso:

These data were collected using funding from the U.S. Government and can be used without additional permissions or fees.