

Previendo o Tamanho de Focos de Incêndio

Classificação multiclasse com KNN, Random Forest e MLP

Estudo aplicado a dados históricos de incêndios florestais nos Estados Unidos

Integrantes:

Paulo Henrique Basso Bessa - RA: 26005799-2

Ricardo Camati - RA: 22014446-2

Caua Cesar da Silva de Oliveira - RA: 23217378-2

Objetivo:

Prever a **classe de tamanho final** de incêndios florestais nos Estados Unidos a partir de dados da ocorrência (localização, ano, dia, estado e causa).

Tarefa de classificação multiclasse — **target FIRE_SIZE_CLASS (A a G)**, comparando três modelos: **KNN, Random Forest e MLP**.

Base de dados:

O dataset utilizado foi o **1.88 Million US Wildfires**, disponibilizado no Kaggle:

<https://www.kaggle.com/datasets/rtatman/188-million-us-wildfires/data>

A base original reúne registros de incêndios florestais nos Estados Unidos entre 1992 e 2015. No arquivo SQLite usado neste projeto, a tabela `Fires` contém **1.880.465 registros**.

Distribuição das classes no dataset completo:

Classe	Registros	Percentual
A	666.919	35,47%
B	939.376	49,95%
C	220.077	11,70%
D	28.427	1,51%
E	14.107	0,75%
F	7.786	0,41%
G	3.773	0,20%

Amostra estratifica (≈ 100.00):

Distribuição da amostra usada na modelagem:	
Classe	Registros na amostra
A	14.000
B	14.000
C	14.000
D	14.000
E	14.000
F	7.786
G	3.773

Features utilizadas:

- **FIRE_YEAR** — ano calendário em que o incêndio foi descoberto ou confirmado.
- **DISCOVERY_DOY** — dia do ano em que o incêndio foi descoberto ou confirmado.
- **STAT_CAUSE_DESCR** — descrição da causa (estatística) do incêndio.
- **FIRE_SIZE** — estimativa da área queimada, em acres, dentro do perímetro final do incêndio.
- **FIRE_SIZE_CLASS** — código da classe de tamanho do incêndio com base no número de acres dentro do perímetro final (A=>0 e ≤0,25; B=0,26–9,9; C=10–99,9; D=100–299; E=300–999; F=1.000–4.999; G=5.000+).
- **LATITUDE** — latitude (NAD83) do ponto de origem do incêndio, em graus decimais.
- **LONGITUDE** — longitude (NAD83) do ponto de origem do incêndio, em graus decimais.
- **OWNER_CODE** — código do proprietário ou entidade responsável pela gestão da terra no ponto de origem do incêndio.
- **STATE** — sigla de duas letras do estado em que o incêndio queimou (ou se originou), conforme designação do relatório.

Feature Set de teste criado (11 no total)


```
FEATURES = {  
    "localizacao": ["LATITUDE", "LONGITUDE"],  
    "localizacao_estado_ano_diaAno": ["LATITUDE", "LONGITUDE", "STATE", "FIRE_YEAR", "DISCOVERY_DOY"],  
    "localizacao_estado_causa": ["LATITUDE", "LONGITUDE", "STATE", "DISCOVERY_DOY", "STAT_CAUSE_DESCR"],  
    "tempo": ["FIRE_YEAR", "DISCOVERY_DOY"],  
    "causa": ["STAT_CAUSE_DESCR"],  
    "estado": ["STATE"],  
    "localizacao_tempo": ["LATITUDE", "LONGITUDE", "FIRE_YEAR", "DISCOVERY_DOY"],  
    "localizacao_causa": ["LATITUDE", "LONGITUDE", "STAT_CAUSE_DESCR"],  
    "localizacao_estado": ["LATITUDE", "LONGITUDE", "STATE"],  
    "causa_estado": ["STAT_CAUSE_DESCR", "STATE"],  
    "todos_sem_fire_size": ["FIRE_YEAR", "DISCOVERY_DOY", "STAT_CAUSE_DESCR", "LATITUDE", "LONGITUDE", "STATE"],  
}
```

Modelos utilizados

Foram testados diferentes conjuntos de features para cada modelo.

Modelo	Parte da disciplina	Descrição
KNN	Parte 1	Classificador baseado nos vizinhos mais próximos.
Random Forest	Parte 2	Conjunto de árvores de decisão treinadas com aleatoriedade.
MLP	Parte 2	Rede neural multicamadas com early_stopping.


Localizacao dos incendios nos EUA por classe de tamanho



Modelo de KNN

ranking	feature_set	accuracy	f1_score	tempo
1	localizacao	34.48%	0.3318	0.16s
2	localizacao_estado	34.41%	0.3310	15.72s
3	localizacao_causa	34.35%	0.3306	16.46s
4	todos_sem_fire_size	33.55%	0.3252	16.90s
5	localizacao_estado_ano_diaAno	33.46%	0.3236	17.38s
6	localizacao_estado_causa	33.13%	0.3193	17.08s
7	localizacao_tempo	32.99%	0.3190	0.19s
8	causa_estado	27.77%	0.2589	13.98s
9	estado	27.49%	0.2436	8.07s
10	tempo	21.78%	0.2060	0.16s
11	causa	21.44%	0.1540	13.06s

Matriz de confusão



Random Forest

ranking	feature_set	accuracy	f1_score	tempo
1	localizacao_tempo	37.28%	0.3666	1.92s
2	localizacao_estado_ano_diaAno	37.21%	0.3655	10.80s
3	todos_sem_fire_size	36.81%	0.3630	12.20s
4	localizacao_estado_causa	35.80%	0.3527	11.03s
5	causa_estado	34.70%	0.3206	0.95s
6	localizacao	34.53%	0.3406	1.51s
7	localizacao_estado	34.45%	0.3406	10.64s
8	localizacao_causa	34.19%	0.3379	11.34s
9	estado	32.98%	0.3079	0.45s
10	causa	25.84%	0.2170	0.44s
11	tempo	23.07%	0.2247	0.69s


Matriz de confusão

Confusion Matrix - localizacao_tempo							Confusion Matrix - localizacao_estado_ano_diaAno						
2408	741	328	240	178	80	25	2448	738	301	256	158	75	24
922	1465	949	442	158	50	14	931	1461	965	422	149	56	16
398	874	1495	847	298	72	16	405	885	1492	808	315	78	17
386	463	873	1344	639	221	74	408	466	874	1312	655	218	67
326	176	331	846	695	269	79	329	180	324	870	677	274	68
201	67	82	370	394	256	93	199	79	90	366	392	248	89
107	15	24	125	140	118	94	97	18	28	114	119	142	105

Confusion Matrix - tempo							Confusion Matrix - causa						
1288	782	681	680	356	162	51	2310	610	429	651	0	0	0
870	953	945	796	307	104	25	1376	1174	780	670	0	0	0
647	852	1137	892	331	109	32	1206	1017	1095	682	0	0	0
719	745	978	944	431	148	35	1579	620	1003	798	0	0	0
591	433	515	656	329	149	49	1304	294	496	628	0	0	0
363	195	194	344	208	109	50	897	87	167	312	0	0	0
151	75	58	125	101	72	41	486	26	34	77	0	0	0

MLP					Matriz de confusão													
ranking	feature_set	accuracy	f1_score	tempo	Confusion Matrix - todos_sem_fire_size							Confusion Matrix - localizacao_estado_causa						
1	todos_sem_fire_size	36.43%	0.3403	3.80s	2532	748	173	366	84	95	2	2513	747	223	390	103	23	1
2	localizacao_estado_causa	35.90%	0.3311	2.75s	1043	1420	792	648	63	33	1	987	1314	914	706	72	7	0
3	localizacao_estado_ano_diaAno	35.43%	0.3285	3.64s	540	814	1391	1095	99	57	4	507	716	1545	1115	97	20	0
4	localizacao_causa	35.34%	0.3359	5.51s	685	429	728	1788	218	146	6	765	369	819	1755	253	39	0
5	localizacao_estado	35.20%	0.3296	5.71s	653	179	246	1227	234	177	6	720	146	273	1249	261	73	0
6	causa_estado	34.99%	0.3249	2.94s	425	62	60	504	200	204	8	492	56	57	548	228	82	0
7	localizacao	34.49%	0.3138	2.75s	210	19	6	134	95	147	12	262	6	8	142	146	58	1
8	localizacao_tempo	34.13%	0.3193	2.01s	Confusion Matrix - causa							Confusion Matrix - tempo						
9	estado	32.79%	0.3060	1.35s	2310	610	429	651	0	0	0	2552	594	854	0	0	0	0
10	causa	25.84%	0.2170	1.14s	1376	1174	780	670	0	0	0	1599	867	1534	0	0	0	0
11	tempo	25.67%	0.1802	1.04s	1206	1017	1095	682	0	0	0	1391	686	1923	0	0	0	0
					1579	620	1003	798	0	0	0	1719	736	1545	0	0	0	0
					1304	294	496	628	0	0	0	1506	424	792	0	0	0	0
					897	87	167	312	0	0	0	1017	187	259	0	0	0	0
					486	26	34	77	0	0	0	508	51	64	0	0	0	0


Comparacao dos melhores resultados por modelo



Amostra de 1 milhão de registros sendo:

- 900.000 mil de treino
- 100.00 mil de teste

Foram em média 4 horas para cada modelo



Conclusão

Os testes e treinamentos mostraram que é **possível prever a classe de tamanho de um incêndio** a partir de fatores como tempo, local e causa.

Predição viável

Os três modelos (KNN, Random Forest e MLP) superaram um palpite baseado apenas na classe majoritária, confirmando a hipótese inicial.

Limitação dos dados

Variáveis climáticas (temperatura, umidade, vento) poderiam melhorar a predição, mas não estavam disponíveis na base utilizada.

Escolha da base

Optamos por este dataset pelo alto volume de registros e pela confiabilidade dos dados, o que trouxe bons resultados mesmo sem variáveis climáticas.

O modelo é um primeiro passo promissor; ampliar as features pode elevar ainda mais a qualidade da predição.